

— GEN-GEN SPEAKER CONSISTENCY

Voice Design TTS 화자 일관성 개선 논문

추가 실험 진행사항

2026.07.27. 미팅

Review

COS/WER 성능 측정

- 지난 주까지의 우리 메서드 SOTA 성능 0.423/WER 0.135에서 WER이 0.12대가 나오는 방법을 찾아보기로 하였음

Instruct Following 성능 측정


- 지난 주에는 INT4로 측정한 성능만 리포트 => 신뢰도 문제
- 이번 주에는 FP8로 돌린 성능을 측정해오기로 하였음

VQ임베딩 토큰 사용 (COS 0.423/WER 0.135)

[1] TEACHER-FORCED RECONSTRUCTION으로 QUERY만 학습



[2] AR 연속 생성



VQ임베딩 토큰 사용 + 임베딩 공간 변형

QwenTTS는 Token 임베딩 공간 차원(D_text)과 Talker의 시퀀스 모델링 공간 차원(2048)이 다름

새로운 시도: 미리 토큰 공간에서 시퀀스 모델링 공간에 투영



기존 방식



공간	수치
Baseline	COS 0.2139/WER 0.1186
기존 SOTA	COS 0.423/WER 0.135
기존 방식 다른 시드	0.415/0.180 · 0.433 /0.149 · 0.403/0.150
미리 토큰 공간 투영	0.398/ 0.130 · 0.392/0.143 · 0.414/0.155
미리 토큰 공간 투영 + Cosine LR	0.414/0.162 · 0.424/0.235

공간	수치
이번주 New 달성	
(딱히 한거 없고 Seed 바뀌서 제일 잘나온거 고름)	COS 0.4212/WER 0.1295

Iteration Step Sweep 결과

학습 이터레이션을 변경했을 때 발생하는 성능 변화 관찰

관찰된 패턴 (projected+cosine, 4 seed)

스텝 구간	경향
너무 적음 (~100 이하)	query가 덜 학습돼 pin 약함 → COS 낮음, 게다가 매우 초반은 불안정 (seed2 step100 = 0.312/0.534 garbage)
중간 (~300)	스윙스팟 — COS 최고이면서 WER 아직 안 깨짐 (s1 step300 = 0.421/0.129, s2 step300 = 0.426/0.155)
너무 많음 (500~600)	COS는 안 오르고, WER이 대체로 붕괴 (s2 step600 0.213, s3 step600 0.269, s4 step400 0.312)

- COS는 스텝에 단조 증가하지 않음: 0.35~0.45를 진동. (batch=1 per-sample 업데이트라 꺾적이 jittery)
- 스텝을 늘리면 WER이 나빠짐: query가 재구성(CE)에 과최적화되며 골라지는 토큰이 점점 "음향적으로 좋지만 텍스트로는 garbage화
- 스텝을 줄이면 pin이 약해 COS가 낮거나, 너무 이르면 불안정
- 그래서 ~300스텝 부근이 최적이고, 그 이상은 무익하거나 해로움

InstructTTEval with Qwen3Ommi (FP8)

세 가지 태스크는 지시문의 구체성 정도에 따라 구분

APS (Acoustic-Parameter Specification): 저수준·구체적 지시

- 성별, 피치, 속도, 볼륨, 감정 등 12개 음향 특징 각각을 명시적으로 지정하는 구조화된 지시문
- 예: "Pitch: High female pitch, rising sharply... / Speed: Rapidly accelerates with panic... / Emotion: Escalating panic, anxiety..."
- 평가 목적: 모델이 각 파라미터를 독립적으로 정확히 제어할 수 있는지 확인
참조 오디오에서 Gemini가 생성한 caption을 그대로 지시문으로 사용

DSD (Descriptive-Style Directive): 중간 수준·자유형식 지시

- APS의 구조화된 지시문을 LLM(GPT-4o)이 자연스러운 서술형 문장으로 재작성한 것 (일부 속성 의도적 누락 -> 불완전한 입력에도 대응하는지)
- 예: "Convey a high-pitched female vocal style, beginning at a normal pitch but climbing markedly under emotional pressure..."
- 평가 목적: 비정형적이고 일부만 명시된 입력에서 적절한 스타일을 일반화하여 추론할 수 있는지 확인

메서드	APS	DSD	RP	Avg
Baseline (VD)	83.9%	85.5%	63.6%	77.7%
Two-stage (VD 후 VC)	64.3%	81.8%	58.2%	68.1%
Fixed Anchor	69.6%	78.2%	60.0%	69.3%
VQ Anchor	75.0%	76.4%	54.5%	68.6%

RP (Role-Play): 고수준·추상적 지시

- 음향 특성을 직접 언급하지 않고, 역할이나 시나리오만 묘사 (예: "전화로 사고를 응급대원에게 설명하려는, 긴박하고 불안한 상태")
- Chain-of-Thought 방식으로 GPT가 12개 특징을 추론한 뒤 역할/시나리오 지시문 생성
- 평가 목적: 모델이 세상 지식과 맥락 추론을 통해 고수준 사회적/상황적 단서를 구체적인 음향으로 스스로 매핑할 수 있는지 확인

InstructTTS Eval with Qwen3Ommi (FP8)

원인 분석 (...!)

일반적 경향

- APS > DSD > RP 순으로 "얼마나 구체적으로 알려주는가"가 줄어듦, 모델이 스스로 추론해야 하는 부분이 늘어나는 구조
- 벤치마크 원본 논문에서 대부분 모델이 APS > DSD > RP 순으로 점수가 낮아지는 경향을 보임

VQ 생성 편향 문제: VQ를 사용할 경우 전반적으로 느린 음성 생성

- median 12.1초 vs 다른 옵션 9.8~10.6초, 25초 초과 클립 16개 vs 9~10개
- 앵커에서 이어 생성하면서 발화가 느리고 단조로운 쪽으로 끌리는 정황으로, 감정 기복·완급이 채점 포인트인 RP/DSD에서 정확히 불리한 방향

판정 노이즈

- 같은 데이터를 다시 평가하면 모델의 True/False 대답이 바뀜
- VQ가 낮은 것이 아닐 가능성
- 원본 논문 코드가 어떻게 이 문제를 제약했는지 확인 필요

메서드	APS	DSD	RP	Avg
Baseline (VD)	83.9%	85.5%	63.6%	77.7%
Two-stage (VD 후 VC)	64.3%	81.8%	58.2%	68.1%
Fixed Anchor	69.6%	78.2%	60.0%	69.3%
VQ Anchor	75.0%	76.4%	54.5%	68.6%

추가적 추정 원인 (가능성)

- **학습 목적함수 자체의 트레이드오프**: COS가 높도록 학습된 상태에서 음색·피치 같은 정적 속성은 오히려 잘 유지되지만, 지시문이 요구하는 극적인 딜리버리 변화에는 좋지 않을 수도 있음
- **Text 공간 오염/충돌**: Fixed 대비 낮은 성능의 원인으로, 자연스러운 영어 문장이 아닌 읽을 수 없는 VQ 임베딩이 서로 간섭하여 프롬프트 지시를 방해했을 가능성