

Consistent TTS 논문

(Voice Design)

논문 작성 준비 진행사항 보고

Review

InstructTTSEval 벤치마크에서 우리 메서드 성능이 애매한 문제

- 예상으로는 Learnable VQ가 더 나은 Instruction Following 성능을 보일 것이라고 기대했으나 실제로는 중간 수준 추론에서 Two-stage 대비 좋은 성능을 보이지 못해 핵심주장에 문제가 발생
- 이에 대한 대응으로 VQ 과정에서의 텍스트 커밋 제거와 데이터셋 증강 두가지를 시도해보기로 함
- 추가로 생성 길이가 늘어지는 문제에 대한 대응도 필요..

메서드	APS	DSD	RP	Avg
Baseline (VD)	83.9%	85.5%	63.6%	77.7%
Two-stage (VD 후 VC)	64.3%	81.8%	58.2%	68.1%
Fixed Anchor	69.6%	78.2%	60.0%	69.3%
VQ Anchor	75.0%	76.4%	54.5%	68.6%

(참고) Instruct Prompt의 3가지 종류

APS (Acoustic-Parameter Specification): 저수준·구체적 지시

- 성별, 피치, 속도, 볼륨, 감정 등 12개 음향 특징 각각을 명시적으로 지정하는 구조화된 지시문
- 예: "Pitch: High female pitch, rising sharply... / Speed: Rapidly accelerates with panic... / Emotion: Escalating panic, anxiety..."
- 평가 목적: 모델이 각 파라미터를 독립적으로 정확히 제어할 수 있는지 확인참조 오디오에서 Gemini가 생성한 caption을 그대로 지시문으로 사용

DSD (Descriptive-Style Directive): 중간 수준·자유형식 지시


- APS의 구조화된 지시문을 LLM(GPT-4o)이 자연스러운 서술형 문장으로 재작성한 것 (일부 속성 의도적 누락 -> 불완전한 입력에도 대응하는지)
- 예: "Convey a high-pitched female vocal style, beginning at a normal pitch but climbing markedly under emotional pressure..."
- 평가 목적: 비정형적이고 일부만 명시된 입력에서 적절한 스타일을 일반화하여 추론할 수 있는지 확인

RP (Role-Play): 고수준·추상적 지시

- 음향 특성을 직접 언급하지 않고, 역할이나 시나리오만 묘사 (예: "전화로 사고를 응급대원에게 설명하려는, 긴박하고 불안한 상태")
- Chain-of-Thought 방식으로 GPT가 12개 특징을 추론한 뒤 역할/시나리오 지시문 생성
- 평가 목적: 모델이 세상 지식과 맥락 추론을 통해 고수준 사회적/ 상황적 단서를 구체적인 음향으로 스스로 매핑할 수 있는지 확인

VQ임베딩 토큰 사용 + 텍스트 커밋 제거

현재 방식: COS 유사도를 희생하고 Instruct 추론 성능 보존을 위해 VQ의 텍스트 커밋 제거 버전으로 복구



이전 방식: 미리 토큰 공간에서 시퀀스 모델링 공간에 투영



공간	수치
Baseline	COS 0.2139/WER 0.1186
기존 SOTA	COS 0.423/WER 0.135
미리 토큰 공간 투영	0.398/ 0.130 · 0.392/0.143 · 0.414/0.155
미리 토큰 공간 투영 + Cosine LR	0.414/0.162 · 0.424/0.235
텍스트 커밋 제거	COS 0.401 / WER 0.131

데이터셋 증강 (프롬프트 다양화)

LibriTTS-P persona를 InstructTTSEval의 세 레지스터 형태로 변환하여 학습에 혼합.

형태	학습 증강 비율	형태	예시
원본	30%	LibriTTS-P persona	ask a high-pitched woman to speak quickly with large volume. The speaker's identity ...
저난도(APS) 추론 대응	25%	12개 'key: value' 블록	gender: A female speaker.` / `pitch: Higher than the average female range ...
중간 난도(DSD) 추론 대응	25%	2인칭 명령형 산문	Deliver this with volume pushed above conversational norms and a brisk pace ...
고난도(RP) 추론 대응	20%	역할 · 시나리오	The quietly assured philosopher lets a hard question sit before answering it ...

- accent, emotion은 LibriTTS-P에 존재하지 않아 생성하지 않고 생략
- >> judge가 accent와 성별 불일치를 즉시 false 처리하므로 없는 라벨을 만드는 것은 위험 부담이 큼
- >> 오히려 비워둔 것에 대한 부수 효과로 "일부만 명시된 지시문"을 학습하게 되어, DSD/RP 능력에 더 유리할 수도 있을 것

최종 성능 (1000개 샘플)

메서드	APS	DSD	RP	Avg
Baseline (VD)	83.9%	85.5%	63.6%	77.7%
Two-stage (VD 후 VC)	64.3%	81.8%	58.2%	68.1%
Fixed Anchor	69.6%	78.2%	60.0%	69.3%
VQ Anchor	75.0%	76.4%	54.5%	68.6%
텍스트 커밋 제거	75.0%	79.8%	56.0%	70.2%

아직은 아쉬운 성능

OTL

- 프롬프트 증강의 효과가 있어 긍정적인 개선이 있었으나
- 확실하게 Two-stage 대비 높은 성능이 나오지 않아서 아쉬움
- 더 확실한 메서드를 찾기 위해 다른 시도를 해볼 예정
 - 예: 입력단 하나에만 VQ를 진행하는 것이 아니라 모든 블록에 VQ 삽입하여 더 적극적으로 적용

* 단, 해당 지표는 아직 메트릭 측정의 일관성을 보장하지 않은 코드로 실험 진행됨 (저지 Ommi LLM 모델이 때로 일관적이지 못하게 결과를 뒤집는 문제가 있으나 해결 방법을 찾는 중)

COS Metric 관련 검증 필요사항 발견

지금까지 사용하던 COS 메트릭 코드에 검토가 필요한 부분 확인

- 아직은 Fable 모델의 주장일 뿐 직접 검증하지 못하였음
- 논문 작성을 위해 코드를 정리/검토하던 중, COS 메트릭 코드에 검토가 필요한 부분을 확인하게 됨
- 기존 COS 메트릭용 라이브러리로 speechbrain을 사용하고 있었는데, 해당 라이브러리의 문제로 제로패딩이 'mean_var_norm'과 ECAPA의 attentive statistics pooling에 그대로 포함되고 있다고 Fable이 주장
- >> 이 경우 길이 편차가 큰 배치일수록 임베딩이 패딩량 방향으로 끌려간다고 함
- >> 그럼 Speaker Drift에 생성 길이 차이까지도 COS 성능에 반영되고 있었다는 것으로 볼 수 있음 (진짜로 맞는 분석이라면)
- 그럼 진짜로 패딩이 성능 측정에 영향을 주고 있던 것이라면, 지금까지 실험했던 여러 VD 개선 방안 중 COS 40대에 근접했던 메서드들도 다시 살펴볼 필요가 있게 됨
- COS 50~60인 VC 모델 수준에 도달하지 못하던 성능상의 아쉬움이 수정 가능해짐
- 또한, 현재 문제 상황인 Learnable VQ가 InstructTTSEval 벤치마크에서 성능이 압도적이지 못한 것을, COS 성능이 낮아서 제외했던 메서드들을 재평가함으로써 극복할 수 있게 될 가능성이 있어 여러 방면으로 재확인을 진행하고자 함

메서드 전이 가능성 검증 | 일정

본격적인 테이블 구성에 있어, 우리 메서드가 다른 모델에 전이 가능한지 확인하기 위해, 구조가 다른 VD 모델 3종에 동일 실험을 진행하여 수치를 확보하고자 함 (VC 3종, VD 3종 구성)

실험군 (Voice Design)

모델	코덱	구조
Parler TTS	RVQ	Enc-Dec
Qwen TTS	RVQ	Dec-Only
OmmiVoice	Flow-matching	Dec-Only

대조군 (Voice Cloning)

모델	코덱	구조
Dia	RVQ	Enc-Dec
Higgs v2	RVQ	Dec-Only
CosyVoice 3	Flow-matching	Dec-Only

비교군과 대조군의 구조 쌍을 동일하게 설정

- 코덱 방식(RVQ / Flow-matching)과 아키텍처(Enc-Dec / Dec-Only)를 교차 선정하여 메서드가 특정 구조에 의존하는지 분리 증명
- 현재 타 모델들 코드 구현 진행 중에 있음 (거의 다 완료됨)

일정 진행

- 다음 주 미팅에서 논문 초안 공유드리는 일정으로 진행 목표