

— GEN-GEN SPEAKER CONSISTENCY · FULL REPORT

# Voice Design TTS

## 화자 일관성 개선 실험 리포트

*Qwen3-TTS-VoiceDesign에서 Gen-Gen COS를 0.60 천장에 얼마나 가까이 붙일 수 있는가*

2026.07.13. 미팅

---

# Contents

01

## Goals

WER과 COS 목표 수치  
+ Learnable 기법

02

## Trials

42개의 실험 결과 리포트

03

## Insights

실험 결과에 대한  
인사이트 정리

04

## Evaluations

Instruction Following  
벤치마크와 관련된 문제상황

*Qwen3-TTS-VoiceDesign에서 Gen-Gen COS를 0.60 천장에 얼마나 가까이 붙일 수 있는가*

2026.07.13. 미팅

— SECTION 01

# 목표 · 설정 · 제약

무엇을 올리고, 무엇을 절대 깨면 안 되는가

01

# 지표는 Gen-Gen COS, 제약은 샘플링과 WER

Goal: COS 50+, Learnable 하면서도 WER이 유지되는 메서드 탐색

## 모델 · 데이터

### Qwen3-TTS-VoiceDesign

talker-only ~1.9B

LibriTTS-P (df1 annotator)

train-clean-100 기반 29,679 발화

persona = combined\_prompt

## 제약 1

### 정상 샘플링 유지

temperature 0.9, top\_k 50 고정

샘플링을 제한하면 Voice Cloning과 달라지므로  
금지

## 제약 2

### WER 보존

base  $\approx 0.124$ , WER-safe 기준 WER  $\lesssim 0.14$

COS를 올려도 WER이 깨지면 그 실험은 무효

## 모티베이션 강화 포인트

### 2-stage 파이프라인의 Instruction Following 성능 병목 주장


선정되는 메서드는 높은 COS 수치 뿐만 아니라 Instruction Following이 잘 될 가능성이 이론적으로 존재하면서 IT 벤치 성능도 잘 나와야 함

# Continuation / Anchor 2단계 입력 구조

[1] 앵커 AR 생성



[2] AR 연속 생성



## CACHED

같은 voice prompt는 앵커 1개를 공유해 재사용

## NO-CACHE

발화마다 KV 캐시 생성을 다시 돌려 fresh 앵커 생성

## FIXED ANCHOR

no-cache 구조 + 앵커 AR 생성 seed 고정 이후 AR은 stochastic

|               | COS     | WER   | UTMOS |
|---------------|---------|-------|-------|
| Baseline      | 0.224   | 0.120 | 3.406 |
| KV 캐시 재사용     | 0.402   | 0.123 | 3.489 |
| KV 캐시 항상 재생성  | 0.269   | 0.122 | 3.461 |
| 화자 쿼리 시 시드 고정 | 0.369** | 0.121 | 3.512 |

— SECTION 02


# 메서드 시도 기록

*Reference Text의 Learnability를 해결하여 Dataset-optimal을 구하면  
더 나은 COS와 IT를 달성할 수 있을까?*


02

# Fixed Prompt 문체 어블레이션

## [1] 앵커 AR 생성



## [2] AR 연속 생성



| #                               | 실험                                            | COS(sim) | WER   | UTMOS | WER-safe | 비고              |
|---------------------------------|-----------------------------------------------|----------|-------|-------|----------|-----------------|
| 베이스라인 / 메커니즘                    |                                               |          |       |       |          |                 |
| B1                              | two-pass sequential (cached, voice prompt 없음) | 0.402    | -0.12 | —     | ✓        | 원본 순차           |
| B2                              | two-pass batched (cached)                     | 0.346    | 0.122 | 3.47  | ✓        | 배치화로 하락         |
| B3                              | two-pass batched (no-cache)                   | 0.269    | 0.122 | 3.46  | ✓        | fresh ref       |
| B4                              | single-pass (cached, voice prompt 보임)         | 0.348    | 0.127 | 3.39  | ✓        |                 |
| B5                              | single-pass (no-cache)                        | 0.266    | 0.127 | 3.40  | ✓        |                 |
| B6                              | single-pass no-cache fixedanchor              | 0.394    | 0.124 | 3.34  | ✓        | WER-safe 기준 베이스 |
| Fixed Reference Text Prompt 템플릿 |                                               |          |       |       |          |                 |
| F1                              | desc_raw                                      | 0.391    | 0.128 | 3.34  | ✓        |                 |
| F2                              | natural                                       | 0.405    | 0.123 | 3.42  | ✓        | 템플릿 중 최고        |
| F3                              | read_aloud                                    | 0.385    | 0.125 | 3.45  | ✓        |                 |
| F4                              | recording                                     | 0.398    | 0.129 | 3.48  | ✓        |                 |
| 앵커 축 (학습 없음)                    |                                               |          |       |       |          |                 |
| A1                              | 앵커 길이 tiny(2tok)                              | 0.336    | 0.124 | 3.32  | ✓        | 너무 짧으면 하락       |
| A2                              | 길이 short(11)                                  | 0.353    | 0.122 | 3.43  | ✓        |                 |
| A3                              | 길이 long(25)                                   | 0.368    | 0.119 | 3.52  | ✓        |                 |
| A4                              | 길이 xlong(47)                                  | 0.352    | 0.117 | 3.47  | ✓        | 포화 미세 하락        |
| A5                              | greedy anchor (seed+greedy)                   | 0.408    | 0.131 | 3.29  | ✓        | 앵커 결정화 소폭 이득    |

### CONTENT 축


- 4가지 문체 템플릿 전부 COS 0.385–0.405, 거의 동일
- reference text는 음색 pin의 축매일 뿐, 문체는 무관
- 이 실험이 content 축이 막다른 길임을 확정

# 고정 reference text를 K개 학습 토큰으로 대체

## [1] TEACHER-FORCED RECONSTRUCTION으로 QUERY만 학습



## [2] AR 연속 생성



| #                               | 실험                                            | COS(sim) | WER   | UTMOS | WER-safe | 비고              |
|---------------------------------|-----------------------------------------------|----------|-------|-------|----------|-----------------|
| 베이스라인 / 메커니즘                    |                                               |          |       |       |          |                 |
| B1                              | two-pass sequential (cached, voice prompt 없음) | 0.402    | -0.12 | —     | ✓        | 원본 순차           |
| B2                              | two-pass batched (cached)                     | 0.346    | 0.122 | 3.47  | ✓        | 메치화로 하락         |
| B3                              | two-pass batched (no-cache)                   | 0.269    | 0.122 | 3.46  | ✓        | fresh ref       |
| B4                              | single-pass (cached, voice prompt 보임)         | 0.348    | 0.127 | 3.39  | ✓        |                 |
| B5                              | single-pass (no-cache)                        | 0.266    | 0.127 | 3.40  | ✓        |                 |
| B6                              | single-pass no-cache fixedanchor              | 0.394    | 0.124 | 3.34  | ✓        | WER-safe 기준 베이스 |
| Fixed Reference Text Prompt 템플릿 |                                               |          |       |       |          |                 |
| F1                              | desc_raw                                      | 0.391    | 0.128 | 3.34  | ✓        |                 |
| F2                              | natural                                       | 0.405    | 0.123 | 3.42  | ✓        | 템플릿 중 최고        |
| F3                              | read_aloud                                    | 0.385    | 0.125 | 3.45  | ✓        |                 |
| F4                              | recording                                     | 0.398    | 0.129 | 3.48  | ✓        |                 |
| 앵커 축 (학습 없음)                    |                                               |          |       |       |          |                 |
| A1                              | 앵커 길이 tiny(2tok)                              | 0.336    | 0.124 | 3.32  | ✓        | 너무 짧으면 하락       |
| A2                              | 길이 short(11)                                  | 0.353    | 0.122 | 3.43  | ✓        |                 |
| A3                              | 길이 long(25)                                   | 0.368    | 0.119 | 3.52  | ✓        |                 |
| A4                              | 길이 xlong(47)                                  | 0.352    | 0.117 | 3.47  | ✓        | 포화 미세 하락        |
| A5                              | greedy anchor (seed+greedy)                   | 0.408    | 0.131 | 3.29  | ✓        | 앵커 결정화 소폭 이득    |



```

graph LR
    A[Voice Prompt  
화자 스타일 지정] --> B[Learnable VQ Embedding  
쿼리된 텍스트 공간 조건]
    B --> C[Reference Audio  
이후 AR 컨디션 (오디오 공간)]
  
```

The diagram illustrates a three-step process for audio generation. It starts with a 'Voice Prompt' (화자 스타일 지정) in a blue box, which leads to a 'Learnable VQ Embedding' (쿼리된 텍스트 공간 조건) in a green box. This step then leads to the 'Reference Audio' (이후 AR 컨디션 (오디오 공간)) in a red box. A large blue arrow points from the first box to the second, and a smaller blue arrow points from the second box to the third.

The diagram illustrates the flow of information in a voice cloning process. It consists of five rectangular boxes connected by arrows. The first box is labeled 'Voice Prompt' with the subtitle '화자 스타일 지정' (Speaker style specification). An arrow points to the second box, 'Learnable VQ Embedding', with the subtitle '쿼리된 텍스트 공간 조건' (Queried text space condition). Another arrow points to the third box, 'Reference Audio', with the subtitle '쿼리된 오디오 공간 조건' (Queried audio space condition). A fourth arrow points to the fourth box, 'Content Prompt', with the subtitle '실제 생성 대상 대사' (Actual target dialogue for generation). Finally, a large arrow points from the fourth box to the fifth box, 'Audio ...', with the subtitle '실제 생성 오디오' (Actual generated audio). The 'Audio ...' box is highlighted with a red border.

| 영커 측 (학습 없음)                                      |                             |       |       |      |      |                      |
|---------------------------------------------------|-----------------------------|-------|-------|------|------|----------------------|
| A1                                                | 영커 길이 tiny(2tok)            | 0.336 | 0.124 | 3.32 | ✓    | 너무 짧으면 하락            |
| A2                                                | 길이 short(11)                | 0.353 | 0.122 | 3.43 | ✓    |                      |
| A3                                                | 길이 long(25)                 | 0.368 | 0.119 | 3.52 | ✓    |                      |
| A4                                                | 길이 xlong(47)                | 0.352 | 0.117 | 3.47 | ✓    | 포화 미세 하락             |
| A5                                                | greedy anchor (seed+greedy) | 0.408 | 0.131 | 3.29 | ✓    | 영커 결정화 소폭 이득         |
| A6                                                | multi-ref M=1               | 0.394 | 0.124 | 3.34 | ✓    | =베이스                 |
| A7                                                | multi-ref M=4               | 0.345 | 0.121 | 3.44 | ✓    | 다중 영커 오히려 하락         |
| A8                                                | multi-ref M=8 (short)       | 0.348 | 0.156 | 3.39 | ⚠    |                      |
| A9                                                | temperature 0.9             | 0.408 | 0.131 | 3.29 | ✓    |                      |
| A10                                               | temperature 0.6             | 0.396 | 0.123 | 3.35 | ✓    |                      |
| A11                                               | temperature 0.3             | 0.696 | 0.194 | 3.13 | ✗ 무효 | 샘플링 제한 → 제약 위반       |
| Learnable Global Query (파라미터화)                    |                             |       |       |      |      |                      |
| G1                                                | raw (k=4, codec-CE만)        | 0.392 | 0.604 | 2.72 | ✗    | off-manifold, WER 붕괴 |
| G2                                                | raw k=4 + sub-talker loss   | 0.404 | 0.422 | 3.39 | ✗    | WER 여전히 붕괴           |
| G3                                                | global residual 벡터          | 0.350 | 0.117 | 3.43 | ✓    | WER-safe but 이득 없음   |
| G4                                                | softmax(vocab 불록결합)         | 0.479 | 0.314 | 3.27 | ✗    | 높은 COS, WER 붕괴       |
| G5                                                | VQ (k=8, ref_text 불일치)      | 0.512 | 0.408 | 3.02 | ✗    | 최고 COS지만 WER 붕괴      |
| G6                                                | linear                      | 0.299 | 0.394 | 2.53 | ✗    | 전부 나쁨                |
| VQ Learnable Global Query in Reftext (k-ablation) |                             |       |       |      |      |                      |

| #                               | 실험                                            | COS(sim)     | WER          | UTMOS       | WER-safe | 비고                     |
|---------------------------------|-----------------------------------------------|--------------|--------------|-------------|----------|------------------------|
| 베이스라인 / 메커니즘                    |                                               |              |              |             |          |                        |
| B1                              | two-pass sequential (cached, voice prompt 없음) | 0.402        | ~0.12        | —           | ✓        | 원본 순차                  |
| B2                              | two-pass batched (cached)                     | 0.346        | 0.122        | 3.47        | ✓        | 배치화로 하락                |
| B3                              | two-pass batched (no-cache)                   | 0.269        | 0.122        | 3.46        | ✓        | fresh ref              |
| B4                              | single-pass (cached, voice prompt 보임)         | 0.348        | 0.127        | 3.39        | ✓        |                        |
| B5                              | single-pass (no-cache)                        | 0.266        | 0.127        | 3.40        | ✓        |                        |
| <b>B6</b>                       | <b>single-pass no-cache fixedanchor</b>       | <b>0.394</b> | <b>0.124</b> | <b>3.34</b> | ✓        | <b>WER-safe 기준 베이스</b> |
| Fixed Reference Text Prompt 템플릿 |                                               |              |              |             |          |                        |
| F1                              | desc_raw                                      | 0.391        | 0.128        | 3.34        | ✓        |                        |
| F2                              | natural                                       | 0.405        | 0.123        | 3.42        | ✓        | 템플릿 중 최고               |
| F3                              | read_aloud                                    | 0.385        | 0.125        | 3.45        | ✓        |                        |
| F4                              | recording                                     | 0.398        | 0.129        | 3.48        | ✓        |                        |
| 앵커 축 (학습 없음)                    |                                               |              |              |             |          |                        |
| A1                              | 앵커 길이 tiny(2tok)                              | 0.336        | 0.124        | 3.32        | ✓        | 너무 짧으면 하락              |
| A2                              | 길이 short(11)                                  | 0.353        | 0.122        | 3.43        | ✓        |                        |
| A3                              | 길이 long(25)                                   | 0.368        | 0.119        | 3.52        | ✓        |                        |
| A4                              | 길이 xlong(47)                                  | 0.352        | 0.117        | 3.47        | ✓        | 포화·미세 하락               |
| A5                              | greedy anchor (seed+greedy)                   | 0.408        | 0.131        | 3.29        | ✓        | 앵커 결정화 소폭 이득           |

| 앵커 측 (학습 없음)                   |                             |              |       |      |      |                      |
|--------------------------------|-----------------------------|--------------|-------|------|------|----------------------|
| A1                             | 앵커 길이 tiny(2tok)            | 0.336        | 0.124 | 3.32 | ✓    | 너무 짧으면 하락            |
| A2                             | 길이 short(11)                | 0.353        | 0.122 | 3.43 | ✓    |                      |
| A3                             | 길이 long(25)                 | 0.368        | 0.119 | 3.52 | ✓    |                      |
| A4                             | 길이 xlong(47)                | 0.352        | 0.117 | 3.47 | ✓    | 포화·미세 하락             |
| A5                             | greedy anchor (seed+greedy) | 0.408        | 0.131 | 3.29 | ✓    | 앵커 결정화 소폭 이득         |
| A6                             | multi-ref M=1               | 0.394        | 0.124 | 3.34 | ✓    | =베이스                 |
| A7                             | multi-ref M=4               | 0.345        | 0.121 | 3.44 | ✓    | 다중 앵커 오히려 하락         |
| A8                             | multi-ref M=8 (short)       | 0.348        | 0.156 | 3.39 | ⚠    |                      |
| A9                             | temperature 0.9             | 0.408        | 0.131 | 3.29 | ✓    |                      |
| A10                            | temperature 0.6             | 0.396        | 0.123 | 3.35 | ✓    |                      |
| A11                            | temperature 0.3             | <b>0.696</b> | 0.194 | 3.13 | ✗ 무효 | 샘플링 제한 → 제약 위반       |
| Learnable Global Query (파라미터화) |                             |              |       |      |      |                      |
| G1                             | raw (k=4, codec-CE만)        | 0.392        | 0.604 | 2.72 | ✗    | off-manifold, WER 붕괴 |
| G2                             | raw k=4 + sub-talker loss   | 0.404        | 0.422 | 3.39 | ✗    | WER 여전히 붕괴           |
| G3                             | global residual 벡터          | 0.350        | 0.117 | 3.43 | ✓    | WER-safe but 이득 없음   |
| G4                             | softmax(vocab 볼록결합)         | 0.479        | 0.314 | 3.27 | ✗    | 높은 COS, WER 붕괴       |
| G5                             | VQ (k=8, ref_text 불일치)      | <b>0.512</b> | 0.408 | 3.02 | ✗    | 최고 COS지만 WER 붕괴      |
| G6                             | linear                      | 0.299        | 0.394 | 2.53 | ✗    | 전부 나뻐                |

#### VQ Learnable Global Query in Reftext (k-ablation)

ref\_text 일치

VQ Learnable Global Query in Reftext (k-ablation)

— ref\_text 일치

|      |          |       |       |      |   |               |
|------|----------|-------|-------|------|---|---------------|
| V1   | vqr k=1  | 0.318 | 0.157 | 3.37 | ⚠ |               |
| V2   | vqr k=4  | 0.347 | 0.131 | 3.25 | ✓ |               |
| V3   | vqr k=8  | 0.382 | 0.137 | 3.04 | ✓ |               |
| V4   | vqr k=16 | 0.347 | 0.132 | 3.26 | ✓ |               |
| V5 ★ | vqr k=32 | 0.423 | 0.135 | 3.20 | ✓ | WER-safe SOTA |

Learnable Per-sample Query / Speaker-Embed  
Generator

|    |                                   |          |   |   |   |                          |
|----|-----------------------------------|----------|---|---|---|--------------------------|
| P1 | persona→query generator (gen_k16) | —        | — | — | ✗ | collapse                 |
| P2 | speaker-embed gen (MLP, CE)       | collapse | — | — | ✗ | per-persona cos 0.96–1.0 |
| P3 | + ECAPA anti-collapse head        | 미미       | — | — | ✗ | λ=10에도 약함                |
| P4 | MiniLM persona encoder 주입         | 0.217    | — | — | ✗ | collapse는 풀렸으나 주입 실패     |
| P5 | 단순 Linear (frozen backbone, CE)   | collapse | — | — | ✗ | div≈1.0 (아래 §7)          |

모델 Fine-tuning / SFT

|    |                                               |       |       |      |   |                      |
|----|-----------------------------------------------|-------|-------|------|---|----------------------|
| S1 | LoRA reconstruction (초기, 레이아웃 오류)             | 0.377 | 0.967 | 0.67 | ✗ | garbage              |
| S2 | reconstruction SFT (streaming, light 150step) | 0.364 | 0.122 | 3.33 | ✓ | WER 유지, COS 이득 없음(l) |
| S3 | ICL 연속화 SFT (v1 aggressive / v2 gentle)       | —     | broke | —    | ✗ | 텍스트 무시               |

|                                                      |                                               |          |       |      |   |                              |
|------------------------------------------------------|-----------------------------------------------|----------|-------|------|---|------------------------------|
| V2                                                   | vqr k=4                                       | 0.347    | 0.131 | 3.25 | ✓ |                              |
| V3                                                   | vqr k=8                                       | 0.382    | 0.137 | 3.04 | ✓ |                              |
| V4                                                   | vqr k=16                                      | 0.347    | 0.132 | 3.26 | ✓ |                              |
| V5 ★                                                 | vqr k=32                                      | 0.423    | 0.135 | 3.20 | ✓ | WER-safe SOTA                |
| Learnable Per-sample Query / Speaker-Embed Generator |                                               |          |       |      |   |                              |
| P1                                                   | persona→query generator (gen_k16)             | —        | —     | —    | ✗ | collapse                     |
| P2                                                   | speaker-embed gen (MLP, CE)                   | collapse | —     | —    | ✗ | per-persona cos 0.96–1.0     |
| P3                                                   | + ECAPA anti-collapse head                    | 미미       | —     | —    | ✗ | $\lambda=10$ 에도 약함           |
| P4                                                   | MiniLM persona encoder 주입                     | 0.217    | —     | —    | ✗ | collapse는 풀렸으나 주입 실패         |
| P5                                                   | 단순 Linear (frozen backbone, CE)               | collapse | —     | —    | ✗ | div $\approx$ 1.0 (아래 §7)    |
| 모델 Fine-tuning / SFT                                 |                                               |          |       |      |   |                              |
| S1                                                   | LoRA reconstruction (초기, 레이아웃 오류)             | 0.377    | 0.967 | 0.67 | ✗ | garbage                      |
| S2                                                   | reconstruction SFT (streaming, light 150step) | 0.364    | 0.122 | 3.33 | ✓ | WER 유지, COS 이득 없음(l)         |
| S3                                                   | ICL 연속화 SFT (v1 aggressive / v2 gentle)       | —        | broke | —    | ✗ | 텍스트 무시                       |
| S4                                                   | joint (backbone LoRA + Linear, CE)            | collapse | broke | —    | ✗ | div 0.9987                   |
| S5                                                   | joint + contrastive spread (LAM=5)            | 0.242    | 0.266 | 2.00 | ✗ | distinct code지만 off-manifold |

— SECTION 03

# 실험 결론/인사이드

실험 결과를 통한 인사이트 도출?

03

## — CONCLUSIONS

# 다섯 가지 종합결론

1. WER-safe SOTA = VQ Learnable Global Query in Reftext,  $k=32$ : COS 0.423 / WER 0.135 / UTMOS 3.20
2. Reference Content 측은 COS와 일정 수치 이상으로는 연관되지 않음 (COS 40이 한계)
3. 생성 결과를 학습 분포 쪽으로 가깝게(더 "그럴듯하게") 만들수록 화자 유사도는 높아지지만 WER 붕괴 — VQ+모델 freeze가 유일한 WER-safe 경로
4. Per-sample(persona > embedding) 계열은 원리적으로 collapse — persona 비구분성 + CE의 무-요구 + one-to-many 문제
5. CE 기반 SFT는 백본을 함께 학습해도 COS를 못 올림 — collapse 또는 텍스트 shortcut 현상 발생

— SECTION 04

# 모델 벤치마크 구축

*Instruction Following* 성능 측정을 위한 벤치마크 환경 구축 과정

04



# SKILL.md 구축을 통한 IT 벤치마크 비용 절감


논문의 주요 주장: 우리 메서드를 쓰면 Two-stage 방식에 비해 IT가 잘된다!

## InstructionTTSEval로 실험 성능 측정이 빠르게 필요

비용 절감 시도: Gemini CLI (Antigravity CLI)의 SKILL로 벤치마크 코드를 변환

1. 발견한 문제: CLI의 입력이 일반적으로 오디오 입력으로 인식되지 않아 '파일 첨부'로 해석 => Gemini가 에이전트 모드로 동작하면서 자기가 듣고 분석하는 것이 아닌 계속 별도 도구를 사용하려고 함 => 5시간 사용량 제한이 너무 빨리 닳아 전체 6000개 샘플을 돌릴 수가 없게 됨
2. 추가 발견 문제: CLI를 통한 동작이 불안정하여, 실제 API를 써서 하는 경우 가격 측정을 위해 6000개 샘플 중 90개만 추출하여 API 요금 확인
3. 90개당 661원 => 6000개 호출 시 44066원 / 그 중 영어 데이터 절반만 계산하면 논문에서 언급된 대로 10달러 근처 (14달러)
4. 그러나 이는 Gemini 3 Flash 모델을 사용하여 계산된 수치로, 논문에서는 Gemini 2.5 Pro 모델을 사용하였기에 실제로 Pro로 사용한다면 더 많은 요금이 부과될 예정
5. 또한, 구글이 Gemini 2.5 모델의 지원을 중단하여 API 발급이 불가능한 상태 => 벤치마크 모델이 무조건 바뀔 예정이라 유의성 주장이 어려움
6. 이걸 NeurlPS를 통과한 EmergentTTSEval도 마찬가지인 상황 (상용 API를 쓰다보니 벤더에서 모델을 드롭하면 그냥 벤치마크가 무효화됨)

# 비용 및 문제점 확인




계산기

공학용

7.34444444444444444444444444444444 × 6000 =

44,066.6666666666666666666666666667



# 비용 및 문제점 확인

Gemini(gemini-3-flash-preview)가 gen\_wav/의 오디오 30개 × 3테스크 = 90개를 심사한 스타일 일관성 통과율입니다:

| 태스크              | 통과율    | 세부                 |
|------------------|--------|--------------------|
| APS (속성 나열형 지시)  | 93.33% | 28/30 통과 (false 2) |
| DSD (자연어 묘사형 지시) | 96.67% | 29/30 통과 (false 1) |
| RP (역할/상황 기반 지시) | 70.00% | 21/30 통과 (false 9) |
| AVG (매크로 평균)     | 86.67% | —                  |

Table 8: Controllable speech generation on InstructTTS-Eval. Performance is measured by Attribute Perception and Synthesis accuracy (APS), Description-Speech Consistency (DSD), and Response Precision (RP). The highest scores are shown in bold.

| Type           | Model                                        | InstructTTS-Eval-ZH |             |             | InstructTTS-Eval-EN |             |             |
|----------------|----------------------------------------------|---------------------|-------------|-------------|---------------------|-------------|-------------|
|                |                                              | APS (↑)             | DSD (↑)     | RP (↑)      | APS (↑)             | DSD (↑)     | RP (↑)      |
| Target Speaker | Gemini-flash                                 | 88.2                | <b>90.9</b> | <b>77.3</b> | <b>92.3</b>         | <b>93.8</b> | <b>80.1</b> |
|                | Gemini-pro                                   | <b>89.0</b>         | 90.1        | 75.5        | 87.6                | 86.0        | 67.2        |
|                | Qwen3TTS-25Hz-1.7B-CustomVoice               | 83.1                | 75.0        | 63.0        | 79.0                | 82.8        | 69.3        |
|                | Qwen3TTS-12Hz-1.7B-CustomVoice               | 83.0                | 77.8        | 61.2        | 77.3                | 77.1        | 63.7        |
|                | GPT-4o-mini-tts                              | 54.9                | 52.3        | 46.0        | 76.4                | 74.3        | 54.8        |
| Voice Design   | Qwen3TTS-12Hz-1.7B-VD                        | <b>85.2</b>         | <b>81.1</b> | <b>65.1</b> | 82.9                | <b>82.4</b> | <b>68.4</b> |
|                | Mimo-Audio-7B-Instruct (Zhang et al., 2025b) | 75.7                | 74.3        | 61.5        | 80.6                | 77.6        | 59.5        |
|                | VoiceSculptor (Hu et al., 2026)              | 75.7                | 64.7        | 61.5        | -                   | -           | -           |
|                | Hume                                         | -                   | -           | -           | <b>83.0</b>         | 75.3        | 54.3        |
|                | VoxInstruct (Zhou et al., 2024)              | 47.5                | 52.3        | 42.6        | 54.9                | 57.0        | 39.3        |
|                | Parler-tts-mini (Lyth & King, 2024)          | -                   | -           | -           | 63.4                | 48.7        | 28.6        |
|                | Parler-tts-large (Lyth & King, 2024)         | -                   | -           | -           | 60.0                | 45.9        | 31.2        |
|                | PromptTTS (Guo et al., 2023)                 | -                   | -           | -           | 64.3                | 47.2        | 31.4        |
|                | PromptStyle (Liu et al., 2023)               | -                   | -           | -           | 57.4                | 46.4        | 30.9        |

우리 메서드를 쓰면 Two-stage 방식에 비해 IT가 잘된다???

## 유의성 확보 방안?

구글이 Gemini 2.5 모델의 지원을 중단하여 API 발급이 불가능한 상태 => 벤치마크 모델이 무조건 바뀔 예정이라 유의성 주장이 어려움

이건 NeurIPS를 통과한 EmergentTTS-Eval도 마찬가지인 상황 (상용 API를 쓰다보니 벤더에서 모델을 드롭하면 그냥 벤치마크가 무효화됨)

=> 오픈소스 모델로의 전환이 필요하다고 사료됨  
메트릭 모델 영구 고정 가능

# 후보 모델

Gemini Pro 모델의 성능을 낼 수 있는 Open 모델 후보

## 판단 기준

- 1. 처음 보는 12-dimension JSON rubric을 그 자리에서 유연하게 따를 수 있는가 ("오디오 특화 학습" 여부보다 더 중요)
- 2. GPU 부담이 감당 가능한가

| 모델                                                                                | 규모                         | 태스크 적합성  | 비고                                                                                     |
|-----------------------------------------------------------------------------------|----------------------------|----------|----------------------------------------------------------------------------------------|
| Qwen3-Omni<br>30B-A3B                                                             | 30B(총)/3B(활성),<br>Q4 ~20GB | ★★★★★    | 오픈소스 중 오디오 이해+추론 SOTA, Gemini 2.5 Pro 능가한다는 벤치마크 근거 있음. 유연한 instruction-following이 검증됨 |
| Kimi-Audio                                                                        | Qwen2.5-7B 백본,<br>~7-8B    | ★★★★     | 크기 대비 가장 균형 잡힌 후보                                                                      |
| Qwen2-Audio-7B                                                                    | 8.2B                       | ★★★      | 가볍고 검증된 구세대 모델. Qwen3-Omni/Kimi-Audio보다 추론력은 한 세대 뒤처짐                                  |
| Eureka-Audio                                                                      | 1.7B                       | ★★★(불확실) | "4~18배 큰 모델과 경쟁"이라는 자체 보고 수치는 인상적이나, 2026.2 공개된 매우 신생 모델이라 제3자가 judge로 검증한 사례가 아직 없음   |
| SALMONN                                                                           | 13B                        | ★★       | 원 논문이 스스로 "task overfitting" 문제를 명시                                                    |
| WavReward/AudioJudge/SpeechLLM-as-Judges/SageLM/GSRM/UniSRM/SpeechJudge/TTS-PRISM |                            | ★★       | 좁은 목적(대화 품질, 쌍대선호 등)으로 후속학습되어 임의 rubric 대응력이 오히려 낮을 수 있음                               |

# 후보 모델 – Qwen3Omni

## 모델 별 분석

### 1순위: Qwen3-Omni-30B-A3B-Thinking

- GPU 부담(Q4로 24GB 소비자 GPU 한 장)은 있지만, 유연한 instruction-following이 가장 검증된 후보고, 이게 이 태스크의 핵심 요구사항
- EmergentTTS-Eval도 실제로 Qwen2.5-Omni를 judge 후보군에 넣어 검증한 선례가 있어(비교 평가 대상으로), 계보상 높은 신뢰도

### 2순위(GPU 제약): Kimi-Audio

- 7-8B로 훨씬 가벼움

### 검증 안 된 다크호스: Eureka-Audio

- 1.7B라 GPU 부담이 사실상 0에 가까워서, 파일럿으로 테스트 해보기 용이
- 다만, judge 용도로 쓰인 선례가 없어서 신뢰 어려움

\*제외 권장: SALMONN, 그리고 WavReward류 특화 judge 모델들은 새로운 임의의 rubric을 유연하게 따르기라는 우리 요구사항과 정확히 반대 방향으로 학습된 위험

